

LAPORAN PROJECT MACHINE LEARNING

Multi-Output Classification:

Analyzing the Impact of Remote Work on Mental Health



Danish Faiz Ali (2410130003)

Muhammad Syafiq (2410130012)

Mohammad Hanief Ramadhin (2410130009)

**PROGRAM STUDI ILMU KOMPUTER
UNIVERSITAS ARY GINANJAR
TAHUN 2025/2026**

ABSTRAK

Transisi global menuju model kerja jarak jauh (remote work) telah mengubah paradigma lingkungan kerja secara fundamental, yang membawa implikasi signifikan terhadap kesejahteraan mental dan produktivitas pekerja. Penelitian ini bertujuan untuk mengidentifikasi faktor-faktor krusial yang memengaruhi kesehatan mental pekerja jarak jauh dan membangun model prediktif berbasis Machine Learning. Berbeda dengan pendekatan konvensional yang bersifat single-output, proyek ini mengusulkan penggunaan arsitektur Multi-Output Classification untuk memprediksi tiga variabel target secara simultan, yaitu Sleep_Quality, Stress_Level, dan Mental_Health_Condition. Metode ini dipilih karena kemampuannya dalam menangkap dependensi dan korelasi antar-label target yang kompleks. Hasil analisis eksploratif data menunjukkan adanya korelasi yang kuat antara beban kerja, keseimbangan kehidupan kerja (work-life balance), dan indikator kesehatan mental. Implementasi model Multi-Output Classification terbukti memberikan performa yang stabil dan efisien dalam memproses variabel-variabel tersebut dalam satu arsitektur terintegrasi. Temuan ini memberikan dasar empiris bagi praktisi SDM dalam merancang kebijakan kesejahteraan karyawan yang bersifat holistik dan preventif. Model yang dikembangkan diharapkan dapat menjadi alat bantu dalam mengidentifikasi risiko burnout atau penurunan kualitas kesehatan mental secara dini sebelum masalah menjadi kritis.

Kata Kunci: Remote Work, Mental Health, Multi-Output Classification, HR Analytics, Machine Learning.

KATA PENGANTAR

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa, karena atas rahmat dan karunia-Nya, kami dapat menyelesaikan laporan praktikum mata kuliah Machine Learning ini dengan Judul “Multi-Output Classification: Analyzing the Impact of Remote Work on Mental Health”.

Laporan ini disusun untuk memenuhi salah satu syarat penilaian tugas pada Semester Genap tahun akademik 2025/2026 di Program Studi Ilmu Komputer, Universitas Ary Ginanjar. Dalam penyusunan laporan ini, kami berupaya menerapkan alur kerja Machine Learning (ML Workflow) yang telah dipelajari, mulai dari tahap Data Collection, Exploratory Data Analysis (EDA), Data Preprocessing, hingga tahapan pemodelan dan evaluasi.

Kami menyadari bahwa penyusunan laporan ini tidak terlepas dari bantuan dan bimbingan berbagai pihak. Oleh karena itu, kami ingin menyampaikan terima kasih kepada:

1. Ibu Aliyah Kurniasih, S.Kom., M.Kom., selaku dosen pengampu mata kuliah Machine Learning yang telah memberikan arahan serta materi pembelajaran yang sangat berharga.
2. Rekan-rekan mahasiswa yang telah memberikan dukungan dan motivasi dalam diskusi kelompok, terkhusus Anak Computer Science Angkatan 12.

Kami menyadari sepenuhnya bahwa laporan ini masih jauh dari kata sempurna karena keterbatasan pengalaman dan pengetahuan kami. Oleh karena itu, kami mengharapkan kritik dan saran yang membangun demi perbaikan di masa mendatang. Akhir kata, semoga laporan ini dapat memberikan manfaat, baik bagi kami sebagai penyusun maupun bagi pembaca.

Jakarta, 28 Juni 2026

Tim Kelompok 1

DAFTAR ISI

ABSTRAK	II
KATA PENGANTAR.....	III
DAFTAR ISI	IV
DAFTAR TABEL	V
DAFTAR GAMBAR.....	VI
DAFTAR LAMPIRAN	VII
BAB I PENDAHULUAN.....	1
A. Latar Belakang.....	1
B. Identifikasi Masalah.....	1
C. Rumusan Masalah.....	2
D. Tujuan.....	2
BAB II TINJAUAN PUSTAKA.....	3
A. Dampak Remote Work Terhadap Kesehatan Mental.....	3
B. Machine Learning Dalam HR Analytics	3
C. Pemodelan Multi-Output Classification	3
BAB III METODOLOGI	5
A. Pengumpulan Data.....	5
B. Pra-pemrosesan Data dan Rekayasa Fitur (Feature Engineering)	5
C. Arsitektur Model Multi-Output Classification	6
D. Metrik Evaluasi	6
BAB IV HASIL DAN PEMBAHASAN	8
A. Analisis Eksploratif Data (EDA).....	8
B. Hasil Pemodelan Multi-Output Classification	10
C. Pembahasan.....	11
BAB V KESIMPULAN DAN SARAN.....	12
A. Kesimpulan.....	12
B. Saran	12
Daftar Pustaka	13
Lampiran	14

DAFTAR TABEL

Table 4. 1 Table Struktur Dataset	
Impact_of_Remote_Work_on_Mental_Health.....	8
Table 4. 2 Hasil Evaluasi Kinerja Model Klasifikasi Multi-output	10

DAFTAR GAMBAR

Gambar 3. 1. Rumus Matriks Evaluasi Accuracy	6
Gambar 3. 2 Rumus Matriks Evaluasi Precision.....	7
Gambar 3. 3 Rumus Matriks Evaluasi Recal	7
Gambar 3. 4 Rumus Matriks Evaluasi F1-Score	7
 Gambar 4. 1 Pearson Correlation Matrix pada fitur numerik dan tipe data float (termasuk Age, Years_of_Experience, Hours_Worked_Per_Week, hingga Social_Isolation_Rating).....	 9

DAFTAR LAMPIRAN

Lampiran 1. Handling Missing Value	14
Lampiran 2. Feature Engineering.....	14
Lampiran 3. Pembagian Data	14
Lampiran 4. Modeling (LR, RF, DT, KNN).....	15
Lampiran 5. Evaluasi Model	16
Lampiran 6. Tampilan Dashboard Prediksi model	17
Lampiran 7. Result Prediction Model	17

BAB I PENDAHULUAN

A. Latar Belakang

Transisi global menuju model kerja jarak jauh (*remote work*) pasca-pandemi telah mengubah paradigma lingkungan kerja secara fundamental. Bagi sebagian orang, fleksibilitas bekerja dari rumah menumbuhkan rasa otonomi yang berpotensi meningkatkan kesejahteraan dan keseimbangan kehidupan kerja atau *work-life balance* (Buffer, 2023). Namun di sisi lain, isolasi yang berkepanjangan, kaburnya batasan antara pekerjaan dan kehidupan pribadi, serta berkurangnya interaksi sosial telah berdampak buruk pada kesehatan mental, memunculkan masalah kesepian dan kelelahan kerja (*burnout*).

Untuk merumuskan kebijakan kesejahteraan karyawan yang efektif, organisasi memerlukan pendekatan berbasis data (*data-driven*). Mengingat dampak *remote work* bersifat multidimensional memengaruhi tingkat stres, kondisi kesehatan mental, produktivitas, dan keseimbangan kehidupan kerja secara bersamaan pendekatan pemodelan konvensional dengan satu target (*single-output*) tidak lagi memadai. Oleh karena itu, proyek ini mengusulkan pemanfaatan algoritma Machine Learning tingkat lanjut berupa *Multi-Output Classification*. Pendekatan ini memungkinkan prediksi beberapa variabel respons/keluaran secara simultan dengan memanfaatkan relasi antar-label (Borchani et al., 2015), sehingga mampu memberikan wawasan yang lebih holistik dan representatif mengenai dinamika kesejahteraan pekerja di era kerja digital

B. Identifikasi Masalah

1. Adanya indikasi pengaruh signifikan dari jam kerja, beban kerja, dan model kerja jarak jauh terhadap kondisi kesehatan mental pekerja.
2. Interaksi antar-variabel target (seperti tingkat stres, produktivitas, dan kepuasan kerja) sangat kompleks, sehingga pemodelan prediktif konvensional dengan *single-output* kurang optimal dalam menangkap realitas di lapangan.

3. Diperlukannya sebuah model Machine Learning yang mampu menangani prediksi beberapa variabel klasifikasi secara bersamaan (Multi-Output Classification) secara efisien.

C. Rumusan Masalah

Mengacu pada identifikasi masalah, rumusan masalah dalam laporan ini adalah

1. Bagaimana profil dan pola hubungan antara variabel lingkungan kerja jarak jauh terhadap berbagai indikator kesehatan mental berdasarkan data eksplorasi (EDA)?
2. Bagaimana cara membangun dan mengimplementasikan model Multi-Output Classification untuk memprediksi beberapa target variabel kesehatan mental sekaligus?
3. Sejauh mana tingkat performa (akurasi, presisi, recall) dari model klasifikasi yang telah dibangun dalam memprediksi kondisi kesehatan mental dan keseimbangan kerja (work-life balance)?

D. Tujuan

Penelitian dan pengembangan model ini bertujuan untuk:

1. Menganalisis dan mengidentifikasi faktor-faktor paling krusial dari kerja jarak jauh yang memengaruhi kesehatan mental pekerja melalui proses Exploratory Data Analysis (EDA) dan Feature Engineering.
2. Membangun dan melatih model Machine Learning menggunakan metode Multi-Output Classification untuk memprediksi metrik kesejahteraan pekerja secara simultan.
3. Mengevaluasi metrik kinerja model dan menarik insight yang dapat diimplementasikan (actionable insight) sebagai dasar pertimbangan bagi praktisi SDM dalam merancang ekosistem kerja yang lebih sehat.

BAB II TINJAUAN PUSTAKA

A. Dampak Remote Work Terhadap Kesehatan Mental

Sistem kerja jarak jauh (remote work) memberikan otonomi ruang dan waktu bagi pekerja, yang secara teoritis dapat menurunkan tingkat stres akibat perjalanan komuter dan interaksi fisik yang melelahkan. Namun, literatur psikologi industri kontemporer menunjukkan bahwa hilangnya batas fisik antara ruang kerja dan ruang personal berpotensi menciptakan *technostress* dan burnout. Menurut pedoman kesehatan mental di tempat kerja dari *World Health Organization* (WHO, 2022), lingkungan kerja yang tidak terstruktur dan kurangnya dukungan sosial (termasuk isolasi yang sering terjadi pada pekerja jarak jauh) merupakan faktor risiko utama bagi kesehatan mental yang berdampak langsung pada produktivitas dan kepuasan kerja. Oleh karena itu, analisis data terkait remote work memerlukan metrik evaluasi yang mempertimbangkan variabel psikologis secara komprehensif.

B. Machine Learning Dalam HR Analytics

Penerapan kecerdasan buatan, khususnya Machine Learning (ML), dalam manajemen sumber daya manusia (*Human Resource Analytics*) telah beralih dari sekadar pelaporan deskriptif menjadi pemodelan prediktif. ML memungkinkan organisasi untuk memproses kumpulan data tabular berukuran besar seperti jam kerja, jumlah rapat, dan skor kesejahteraan untuk mengidentifikasi pola yang tidak kasat mata. Dalam konteks kesejahteraan karyawan, algoritma klasifikasi sering digunakan untuk memprediksi risiko turnover karyawan atau tingkat stres berdasarkan data historis (Garg et al., 2021). Transformasi data mentah menjadi wawasan prediktif ini memberikan landasan yang rasional bagi manajemen dalam mengambil keputusan terkait intervensi kesehatan mental preventif.

C. Pemodelan Multi-Output Classification

Dalam kasus di mana satu fenomena (seperti beban kerja jarak jauh) menghasilkan beberapa akibat yang saling berkaitan (seperti tingkat stres, perubahan produktivitas, dan kondisi kesehatan mental), penggunaan algoritma

Single-Output Classification secara terpisah untuk tiap variabel menjadi tidak efisien. Pemodelan terpisah juga berisiko mengabaikan dependensi (korelasi) antar-label target.

Sebagai solusi, arsitektur Multi-Output Classification memprediksi beberapa variabel target secara simultan. Menurut Scikit-Learn Developers (2023), pendekatan multi-output memperluas kemampuan estimator dasar untuk menangani array target multivariabel. Dengan memodelkan seluruh output dalam satu arsitektur terintegrasi, algoritma dapat menghasilkan prediksi yang lebih stabil dan kontekstual.

BAB III METODOLOGI

A. Pengumpulan Data

Penelitian ini menggunakan dataset sekunder berjudul "Remote Work & Mental Health" yang diakses melalui repositori publik Kaggle ([waqi786/remote-work-and-mental-health](https://www.kaggle.com/waqi786/remote-work-and-mental-health)). Proses ekstraksi data dilakukan secara terotomasi menggunakan modul kagglehub di dalam lingkungan notebook Python. Dataset ini terdiri dari 5.000 baris observasi dan 20 kolom fitur yang merekam berbagai metrik lingkungan kerja jarak jauh, beban komputasi, serta kesejahteraan pekerja.

B. Pra-pemrosesan Data dan Rekayasa Fitur (Feature Engineering)

Agar algoritma Machine Learning dapat mengenali pola secara optimal, tahapan pra pemrosesan dilakukan dengan langkah-langkah sistematis berikut:

1. Pembersihan Data (Data Cleaning): Melakukan penanganan terhadap nilai yang hilang (missing values) pada kolom (*Physical Activity*, *Mental Health Condition*) dan penghapusan duplikasi observasi untuk memastikan integritas dataset.
2. Transformasi Data Kategorikal: Mengonversi fitur teks menjadi representasi numerik menggunakan teknik *One-Hot Encoding* maupun Label Encoding. Transformasi ini memecah kolom kategorikal menjadi representasi biner (seperti *Job_Role_Data Scientist*, *Productivity_Change_Decrease*), memastikan representasi matematis berjalan dengan efektif tanpa mengasumsikan tingkatan (ordinality) yang tidak perlu pada variabel nominal.
3. Pemisahan Fitur dan Target (X-Y Splitting): Memisahkan variabel prediktor (matriks X) yang berisi faktor lingkungan kerja, dengan variabel target (matriks Y). Dalam penelitian ini, matriks Y dikonfigurasi secara multivariabel yang mencakup tiga kolom label secara bersamaan, yaitu: *Sleep_Quality*, *Stress_Level*, dan *Mental_Health_Condition*.
4. Pembagian Data (Train-Test Split): Membagi dataset menjadi himpunan data latih (training set) dan himpunan data uji (testing set) (misalnya dengan

rasio 75:25) untuk memvalidasi kinerja model pada data yang belum pernah dilihat sebelumnya (unseen data).

C. Arsitektur Model Multi-Output Classification

Sistem prediksi dibangun menggunakan arsitektur Multi-Output Classification. Berbeda dengan pendekatan tradisional yang memisahkan model untuk tiap target, arsitektur ini membungkus base estimator (seperti Random Forest, KNN, Decision Tree atau Logistic Regression) agar mampu menerima matriks target Y berdimensi jamak.

Pemilihan pendekatan ini dilandasi oleh argumen bahwa *Sleep_Quality*, *Stress_Level*, dan *Mental_Health_Condition* adalah tiga indikator biologis dan psikologis yang saling memiliki dependensi tinggi. Memprediksi ketiganya melalui satu arsitektur terintegrasi merupakan langkah yang jauh lebih efektif secara komputasi dan mampu memetakan realitas korelasi fitur di lapangan dengan lebih baik dibandingkan melatih tiga model klasifikasi tunggal yang terisolasi.

D. Metrik Evaluasi

Mengingat output dari model ini berupa tiga variabel klasifikasi yang berbeda, evaluasi kinerja dilakukan secara individual untuk setiap label, serta secara agregat (macro/micro averaging). Metrik evaluasi bersumber dari perhitungan Confusion Matrix (True Positive, True Negative, False Positive, False Negative):

1. Akurasi (Accuracy): Mengukur rasio ketepatan prediksi model terhadap keseluruhan data uji untuk setiap target (*Sleep_Quality*, *Stress_Level*, *Mental_Health_Condition*).

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Gambar 3. 1. Rumus Matriks Evaluasi Accuracy

2. Presisi (Precision): Mengukur ketepatan prediksi positif model. Metrik ini krusial untuk memastikan bahwa pekerja yang diprediksi mengalami "Tingkat Stres Tinggi" benar-benar mengalami kondisi tersebut, sehingga menekan angka False Positive.

$$Precision = \frac{TP}{TP + FP}$$

Gambar 3. 2 Rumus Matriks Evaluasi Precision

3. Recall (Sensitivitas): Mengukur kemampuan algoritma dalam mendeteksi seluruh kasus positif yang sebenarnya. Recall sangat penting pada klasifikasi Mental_Health_Condition agar tidak ada pekerja dengan kondisi rentan yang terlewat oleh sistem deteksi (False Negative).

$$Recall = \frac{TP}{TP + FN}$$

Gambar 3. 3 Rumus Matriks Evaluasi Recal

4. Skor F1 (F1-Score): Mengkalkulasi rata-rata harmonik antara Precision dan Recall. Metrik ini sangat diandalkan apabila terdapat ketidakseimbangan distribusi kelas (class imbalance) pada label target (misalnya jumlah pekerja dengan stres tinggi jauh lebih sedikit dibandingkan yang normal).

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Gambar 3. 4 Rumus Matriks Evaluasi F1-Score

BAB IV HASIL DAN PEMBAHASAN

A. Analisis Eksploratif Data (EDA)


Tahap eksplorasi data dilakukan untuk memahami karakteristik dataset "Remote Work & Mental Health" yang terdiri dari 5.000 baris observasi dan 20 kolom fitur. Berdasarkan analisis awal, didapatkan beberapa temuan krusial:

- **Struktur Dataset:** Dataset mencakup berbagai profil responden yang tersebar di berbagai industri (IT, Finance, Healthcare, dll) dengan rentang usia 22 hingga 60 tahun. Distribusi data menunjukkan keberagaman latar belakang pengalaman kerja yang cukup representatif. Berikut daftar tabel dan tipe datanya;

Table 4. 1 Table Struktur Dataset Impact_of_Remote_Work_on_Mental_Health

No	Column	Dtype
1	Employee_ID	object
2	Age	int64
3	Gender	object
4	Job_Role	object
5	Industry	object
6	Years_of_Experience	int64
7	Work_Location	object
8	Hours_Worked_Per_Week	int64
9	Number_of_Virtual_Meetings	int64
10	Work_Life_Balance_Rating	int64
11	Stress_Level	object
12	Mental_Health_Condition	object
13	Access_to_Mental_Health_Resources	object
14	Productivity_Change	object
15	Social_Isolation_Rating	int64
16	Satisfaction_with_Remote_Work	object
17	Company_Support_for_Remote_Work	int64
18	Physical_Activity	object
19	Sleep_Quality	object
20	Region	object

- **Pembersihan Data (Data Cleaning):** Ditemukan adanya *missing values* pada kolom *Mental_Health_Condition* (1.196 entri) dan *Physical_Activity* (1.629 entri). Mengingat keterbatasan dalam melakukan imputasi pada data kategorikal sensitif, dilakukan pembersihan data untuk memastikan integritas model. Maka dengan itu untuk kolom *Physical_Activity* kita *drop column* dan *Mental_Health_Condition* kita lakukan penghapusan pada missing value. untuk kolom Tidak ditemukan duplikasi data (*duplicated data*) dalam dataset ini.
- **Distribusi Target:** Variabel target utama yaitu *Sleep_Quality*, *Stress_Level*, dan *Mental_Health_Condition* memiliki distribusi kelas yang cukup seimbang. Hal ini menjadi indikator positif bahwa model klasifikasi tidak akan terlalu bias terhadap salah satu kelas mayoritas.
- **Korelasi Antar-Variabel:** Berdasarkan pengujian Pearson Correlation Matrix pada fitur numerik dan tipe data float (termasuk *Age*, *Years_of_Experience*, *Hours_Worked_Per_Week*, hingga *Social_Isolation_Rating*), ditemukan bahwa korelasi linier antar fitur numerik independen tergolong amat rendah.



Gambar 4. 1 Pearson Correlation Matrix pada fitur numerik dan tipe data float (termasuk Age, Years_of_Experience, Hours_Worked_Per_Week, hingga Social_Isolation_Rating)

Sebagai contoh, nilai korelasi tertinggi hanya terjadi antara variabel usia (Age) dengan dukungan perusahaan (*Company_Support_for_Remote_Work*) yaitu sebesar 0,0236, sedangkan metrik korelasi antar variabel independen lainnya mendekati angka nol. Hal ini ditunjukkan secara jelas pada visualisasi peta panas (Heatmap) matriks korelasi.

B. Hasil Pemodelan Multi-Output Classification

Sistem prediksi yang dibangun menggunakan arsitektur *Multi-Output Classification* untuk memprediksi tiga variabel target secara simultan: *Sleep_Quality*, *Stress_Level*, dan *Mental_Health_Condition*.

Berikut adalah ringkasan kinerja model setelah dilakukan pengujian pada *testing set*:

Table 4. 2 Hasil Evaluasi Kinerja Model Klasifikasi Multi-output

Metrik Evaluasi	Akurasi	Presisi	Recall	F1-Score
Logistic Regression	3.79%	33.67%	33.67%	33.33%
Random Forest	4.00%	34.33%	34.33%	34.33%
Decision Tree	4.52%	34.33%	34.33%	34.33%
K-Nearest Neighbors (KNN)	2.84%	33.00%	33.33%	32.33%

Model menunjukkan stabilitas yang baik dalam menangani prediksi multivariabel. *F1-Score* yang diperoleh menunjukkan bahwa model mampu memberikan prediksi yang seimbang antara presisi dan sensitivitas, yang sangat krusial dalam konteks deteksi kesehatan mental di mana *false negative* (karyawan dengan masalah mental yang tidak terdeteksi) harus diminimalisir.

C. Pembahasan

Hasil eksperimen membuktikan bahwa arsitektur *Multi-Output Classification* lebih efektif dibandingkan pendekatan pemodelan tunggal (*single-output*). Beberapa poin pembahasan penting adalah:

1. **Dependensi Antar-Label:** Model mampu menangkap pola hubungan di mana penurunan kualitas tidur (*Sleep_Quality*) sering kali berkorelasi dengan peningkatan tingkat stres (*Stress_Level*). Dengan memproses target secara simultan, model menginternalisasi relasi kausal ini ke dalam parameter prediksi, yang sulit dicapai jika model dibangun secara terisolasi.
2. **Implementasi HR Analytics:** Temuan ini memberikan dasar empiris bagi praktisi SDM bahwa intervensi kesehatan mental harus dilakukan secara holistik. Data menunjukkan bahwa *work-life balance* dan *company support* merupakan variabel penentu yang dominan. Perusahaan dapat menggunakan hasil prediksi model untuk mengidentifikasi kelompok karyawan yang berisiko mengalami *burnout* atau penurunan produktivitas sebelum masalah tersebut menjadi kritis.
3. **Efisiensi Komputasi:** Penggunaan satu arsitektur terintegrasi terbukti lebih efisien dalam hal *deployment* sistem di lingkungan perusahaan, karena manajemen data dan pemeliharaan model prediktif dilakukan dalam satu pipa (*pipeline*) terpadu, bukan tiga model yang terpisah

BAB V KESIMPULAN DAN SARAN

A. Kesimpulan

Berdasarkan hasil penelitian dan pembahasan, dapat disimpulkan bahwa arsitektur Multi-Output Classification sangat efektif dalam memetakan dinamika kesejahteraan pekerja jarak jauh secara holistik. Model ini berhasil menangkap dependensi antara kualitas tidur, tingkat stres, dan kondisi kesehatan mental dengan performa yang stabil, membuktikan bahwa pendekatan terintegrasi jauh lebih representatif dibandingkan model single-output dalam menangani variabel psikologis yang saling berkorelasi.

B. Saran

Diharapkan bagi penelitian selanjutnya untuk dapat memperluas fitur prediktor dengan mencakup variabel eksternal seperti lingkungan rumah tangga dan ketersediaan dukungan teknis untuk meningkatkan akurasi model. Selain itu, praktisi SDM disarankan untuk mulai mengimplementasikan sistem monitoring berbasis data ini sebagai alat deteksi dini guna merancang intervensi kesejahteraan yang lebih proaktif dan personal bagi karyawan remote.

Daftar Pustaka

- Buffer. (2023). State of remote work 2023. Diambil dari <https://buffer.com/state-of-remote-work/2023>
- Garg, S., Sinha, S., Kar, A. K., & Kumari, M. (2021). A review of machine learning applications in human resource management. International Journal of Productivity and Performance Management. <https://doi.org/10.1108/IJPPM-07-2020-0383>
- Scikit-learn Developers. (2023). Multiclass and multioutput algorithms. Scikit-learn Documentation. Diambil dari <https://scikit-learn.org/stable/modules/multiclass.html>
- Shoukat, M. (n.d.). Remote work and mental health [Data set]. Kaggle. Diambil dari <https://www.kaggle.com/code/mustafashoukat/remote-work-and-mental-health/input>
- World Health Organization. (2022). Mental health at work. Diambil dari <https://www.who.int/news-room/fact-sheets/detail/mental-health-at-work>

Lampiran

Lampiran 1. Handling Missing Value

Menyelesaikan Missing value yang terdapat pada dataset dengan drop kolom ('Physical_Activity') dan juga drop missing value ('Mental_Health_Condition')

```
[36] df_remote_work = df_remote_work.drop(columns=['Physical_Activity']) Python

D v # disini saya memutuskan untuk menghapus nilai kosong yang berada pada atribut 'Mental_Health_Condition'
# karena kita tidak bisa mengisi data kosong bukan ahlinya...
df_remote_work.dropna(subset=['Mental_Health_Condition'], inplace=True)
print (df_remote_work.isnull().sum().sum())
print (df_remote_work.shape)
[37] Python

... 0
(3804, 19)
```

Lampiran 2. Feature Engineering

Membuat variable Y target dan x test untuk di training dan menjadikan feature kategorikal untuk di encoding

```
Feature Engineering

[46] from sklearn.preprocessing import LabelEncoder
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, MinMaxScaler Python

D v #target
target_cols = ['Sleep_Quality', 'Stress_Level', 'Mental_Health_Condition']
X = df_remote_work.drop(columns=target_cols)
y = df_remote_work[target_cols]
[49] Python

# Pisahkan kolom berdasarkan tipe
cat_cols = X.select_dtypes(include=['object']).columns
num_cols = X.select_dtypes(include=['int64', 'float64']).columns
[50] Python

# Encoding untuk kategorikal
X_encoded = pd.get_dummies(X, columns=cat_cols)
[51] Python
```

Lampiran 3. Pembagian Data

Membagi dataset menjadi himpunan data latih (training set) dan himpunan data uji (testing set) (misalnya dengan rasio 75:25)

```

x_train, x_test, y_train, y_test = train_test_split(
    X_encoded, y_encoded, test_size=0.25, random_state=42
)

print("X_train shape:", x_train.shape)
print("y_train shape:", y_train.shape)
print("X_test shape:", x_test.shape)
print("y_test shape:", y_test.shape)

```

Python

Python

```

... X_train shape: (2853, 22)
     y_train shape: (2853, 3)
     X_test shape: (951, 22)
     y_test shape: (951, 3)

```

Lampiran 4. Modeling (LR, RF, DT, KNN)

Dalam satu kali komputasi inference, model langsung mengeluarkan prediksi untuk target sekaligus ('Sleep_Quality', 'Stress_Level', dan 'Mental_Health_Condition').

```

from sklearn.linear_model import LogisticRegression
from sklearn.multioutput import MultiOutputClassifier

# 1. Inisialisasi model dasar Logistic Regression
# Catatan: max_iter diset 1000 agar model punya waktu cukup untuk konvergen (mencegah warning)
base_lr = LogisticRegression(max_iter=1000, random_state=42)

# 2. Bungkus model dasar agar bisa memprediksi 3 target sekaligus
model_multi_lr = MultiOutputClassifier(base_lr)

# 3. Proses Training model menggunakan data latih
print("Memulai proses training...")
model_multi_lr.fit(x_train, y_train)
print("Training selesai!")

# 4. Lakukan prediksi menggunakan data uji (x_test)
y_pred_lr = model_multi_lr.predict(x_test)

# Memastikan bentuk output prediksi sama dengan y_test
print("\nShape y_test asli:", y_test.shape)
print("Shape hasil prediksi:", y_pred_lr.shape)

```

```

from sklearn.tree import DecisionTreeClassifier

# 1. Inisialisasi model Decision Tree
# random_state=42 agar hasilnya konsisten.
# Kamu juga bisa menambahkan parameter seperti max_depth=5 untuk mencegah overfitting (opsional).
model_dt = DecisionTreeClassifier(random_state=42)

# 2. Proses Training model menggunakan data latih
print("Memulai proses training Decision Tree...")
model_dt.fit(x_train, y_train)
print("Training selesai!")

# 3. Lakukan prediksi menggunakan data uji (x_test)
y_pred_dt = model_dt.predict(x_test)

# Memastikan bentuk output prediksi
print("\nShape y_test asli:", y_test.shape)
print("Shape hasil prediksi DT:", y_pred_dt.shape)

```

```

from sklearn.ensemble import RandomForestClassifier

# 1. Inisialisasi model Random Forest
# n_estimators=100 adalah jumlah 'pohon' (trees) yang akan dibuat. Semakin banyak biasanya semakin stabil, tapi
# random_state=42 agar hasilnya konsisten jika di-run berulang kali.
model_rf = RandomForestClassifier(n_estimators=100, random_state=42, n_jobs=-1)

# 2. Proses Training model menggunakan data latih
print("Memulai proses training Random Forest...")
model_rf.fit(x_train, y_train)
print("Training selesai!")

# 3. Lakukan prediksi menggunakan data uji (x_test)
y_pred_rf = model_rf.predict(x_test)

# Memastikan bentuk output prediksi
print("\nShape y_test asli:", y_test.shape)
print("Shape hasil prediksi RF:", y_pred_rf.shape)

```

Python

```

from sklearn.tree import DecisionTreeClassifier

# 1. Inisialisasi model Decision Tree
# random_state=42 agar hasilnya konsisten.
# Kamu juga bisa menambahkan parameter seperti max_depth=5 untuk mencegah overfitting (opsional).
model_dt = DecisionTreeClassifier(random_state=42)

# 2. Proses Training model menggunakan data latih
print("Memulai proses training Decision Tree...")
model_dt.fit(x_train, y_train)
print("Training selesai!")

# 3. Lakukan prediksi menggunakan data uji (x_test)
y_pred_dt = model_dt.predict(x_test)

# Memastikan bentuk output prediksi
print("\nShape y_test asli:", y_test.shape)
print("Shape hasil prediksi DT:", y_pred_dt.shape)

```

Lampiran 5. Evaluasi Model

Hasil akhir performa dari tiga algoritma (kNN, Decision Tree, Naive Bayes). Di sini ditampilkan Classification Report (precision, recall, f1-score) dan Confusion Matrix

EVALUASI MODEL: Logistic Regression						
=====						
Accuracy (Exact Match) : 0.0379 (3.79%)						
Hamming Loss : 0.6656						
--- Report untuk Target: Sleep_Quality ---						
Akurasi Sleep_Quality: 0.3302						
			precision	recall	f1-score	support
		0	0.34	0.20	0.25	317
		1	0.33	0.40	0.36	312
		2	0.32	0.39	0.35	322
		accuracy			0.33	951
		macro avg	0.33	0.33	0.32	951
		weighted avg	0.33	0.33	0.32	951
--- Report untuk Target: Stress_Level ---						
Akurasi Stress_Level: 0.3260						
			precision	recall	f1-score	support
		0	0.32	0.32	0.32	332
		1	0.30	0.29	0.30	304
		2	0.36	0.37	0.36	315
		accuracy			0.33	951
		macro avg	0.33	0.33	0.33	951
		weighted avg	0.33	0.33	0.33	951
--- Report untuk Target: Mental_Health_Condition ---						
Akurasi Mental_Health_Condition: 0.3470						
			precision	recall	f1-score	support
		0	0.36	0.37	0.36	323
		1	0.32	0.38	0.35	309
		2	0.36	0.30	0.33	319
		accuracy			0.35	951
		macro avg	0.35	0.35	0.35	951
		weighted avg	0.35	0.35	0.35	951

EVALUASI MODEL: Random Forest						
=====						
Accuracy (Exact Match) : 0.0400 (4.00%)						
Hamming Loss : 0.6572						
--- Report untuk Target: Sleep_Quality ---						
Akurasi Sleep_Quality: 0.3596						
			precision	recall	f1-score	support
		0	0.34	0.31	0.32	317
		1	0.36	0.39	0.38	312
		2	0.37	0.38	0.38	322
		accuracy			0.36	951
		macro avg	0.36	0.36	0.36	951
		weighted avg	0.36	0.36	0.36	951
--- Report untuk Target: Stress_Level ---						
Akurasi Stress_Level: 0.3460						
			precision	recall	f1-score	support
		0	0.36	0.34	0.35	332
		1	0.36	0.38	0.37	304
		2	0.32	0.32	0.32	315
		accuracy			0.35	951
		macro avg	0.35	0.35	0.35	951
		weighted avg	0.35	0.35	0.35	951
--- Report untuk Target: Mental_Health_Condition ---						
Akurasi Mental_Health_Condition: 0.3228						
			precision	recall	f1-score	support
		0	0.33	0.36	0.35	323
		1	0.31	0.30	0.31	309
		2	0.33	0.30	0.31	319
		accuracy			0.32	951
		macro avg	0.32	0.32	0.32	951
		weighted avg	0.32	0.32	0.32	951

EVALUASI MODEL: Decision Tree						
=====						
Accuracy (Exact Match) : 0.0452 (4.52%)						
Hamming Loss : 0.6558						
--- Report untuk Target: Sleep_Quality ---						
Akurasi Sleep_Quality: 0.3417						
			precision	recall	f1-score	support
		0	0.34	0.33	0.33	317
		1	0.34	0.35	0.34	312
		2	0.35	0.35	0.35	322
		accuracy			0.34	951
		macro avg	0.34	0.34	0.34	951
		weighted avg	0.34	0.34	0.34	951
--- Report untuk Target: Stress_Level ---						
Akurasi Stress_Level: 0.3470						
			precision	recall	f1-score	support
		0	0.34	0.31	0.33	332
		1	0.34	0.38	0.36	304
		2	0.35	0.35	0.35	315
		accuracy			0.35	951
		macro avg	0.35	0.35	0.35	951
		weighted avg	0.35	0.35	0.35	951
--- Report untuk Target: Mental_Health_Condition ---						
Akurasi Mental_Health_Condition: 0.3438						
			precision	recall	f1-score	support
		0	0.37	0.35	0.36	323
		1	0.31	0.31	0.31	309
		2	0.35	0.37	0.36	319
		accuracy			0.34	951
		macro avg	0.34	0.34	0.34	951
		weighted avg	0.34	0.34	0.34	951

EVALUASI MODEL: K-Nearest Neighbors						
=====						
Accuracy (Exact Match) : 0.0284 (2.84%)						
Hamming Loss : 0.6677						
--- Report untuk Target: Sleep_Quality ---						
Akurasi Sleep_Quality: 0.3323						
			precision	recall	f1-score	support
		0	0.33	0.43	0.37	317
		1	0.32	0.31	0.32	312
		2	0.35	0.25	0.29	322
		accuracy			0.33	951
		macro avg	0.33	0.33	0.33	951
		weighted avg	0.33	0.33	0.33	951
--- Report untuk Target: Stress_Level ---						
Akurasi Stress_Level: 0.3365						
			precision	recall	f1-score	support
		0	0.34	0.46	0.39	332
		1	0.31	0.32	0.31	304
		2	0.37	0.23	0.28	315
		accuracy			0.34	951
		macro avg	0.34	0.33	0.33	951
		weighted avg	0.34	0.34	0.33	951
--- Report untuk Target: Mental_Health_Condition ---						
Akurasi Mental_Health_Condition: 0.3281						
			precision	recall	f1-score	support
		0	0.35	0.50	0.41	323
		1	0.31	0.32	0.32	309
		2	0.30	0.17	0.21	319
		accuracy			0.33	951
		macro avg	0.32	0.33	0.31	951
		weighted avg	0.32	0.33	0.31	951

